Kapitel 3: KI-Tools nachvollziehbar vergleichen

Nordlicht KI-Werkstatt GmbH · Fassung v2 · Stand 21.10.2026

1. Ausgangslage

Die Nordlicht KI-Werkstatt prüft heute jeden Kundenwunsch von Hand gegen einen von fünf Verträgen (Kapitel 1). Aus der Analyse in Kapitel 2 ergibt sich der Umfang, den die Werkzeuge leisten müssen. Ein Agent soll

1. Kontaktdaten und Bankverbindungen unkenntlich machen, bevor ein Sprachmodell den Text sieht,
2. jede Kundenäußerung einordnen: Fehlermeldung, Überlegung, Wunsch, Auftrag oder Sonstiges,
3. bei Aufträgen, Wünschen und Überlegungen vorschlagen, ob sie im Vertrag enthalten oder eine Zusatzleistung sind, mit Kategorie, wörtlichem Zitat der Vertragsstelle, Begründung und Sicherheitswert, und dabei prüfen, ob das Kontingent des Kunden noch reicht.

Den Preis rechnet eine feste Regel, jeden Vorschlag gibt die Projektleitung frei. Dieses Kapitel vergleicht, mit welchem Aufbau sich das am besten umsetzen lässt. Für die empfohlene Variante liegen bereits erste Messungen aus einem Probebetrieb vor. Wir kennzeichnen im Text, was **gemessen** ist und was eine **Einschätzung** bleibt, die die Testphase (Kapitel 5) überprüft.

2. Anforderungen aus dem Alltag des Softwarehauses

- **Datenschutz:** Kontaktdaten und Bankverbindungen werden unkenntlich gemacht, bevor ein Text das Haus verlässt. Kundentexte gehen nur an Dienstleister, mit denen ein Vertrag zur Auftragsverarbeitung besteht. Im Projekt fließen ausschließlich erfundene Daten.
- **Vollständigkeit:** Fehlermeldungen und Reklamationen werden aussortiert und weitergeleitet, sie gehen nie verloren.
- **Nachvollziehbarkeit:** Jeder Vorschlag nennt Vertragsstelle, Kategorie, Begründung und Sicherheitswert, so wie es die Verträge für das Protokoll verlangen.
- **Kontingente:** Der Agent kennt das Kontingent jedes Kunden (Stunden oder Seiten laut Vertrag) und legt es zusammen mit dem höchstmöglichen Verbrauch der Änderung vor. Er liest das Konto nur, gebucht wird nach der Umsetzung von Hand.
- **Kontrolle:** Der Preis kommt aus einer Regel. Die Projektleitung gibt jeden Vorschlag frei. Der Agent schreibt nie selbst an Kunden.
- **Integration:** Der Agent arbeitet mit dem, was das Haus schon nutzt: E-Mail, Ticketsystem, Vertragsablage in Google Drive, Stundenkonten in Google Sheets. Die Freigabe läuft über E-Mail oder einen Chatkanal wie Slack.
- **Betrieb:** Ein Haus mit neun Mitarbeitenden und ohne eigene IT-Abteilung muss ihn betreiben können. Neue Verträge kommen ohne Umbau dazu.
- **Wirtschaftlichkeit:** Je Durchgang soll der eingesparte Arbeitslohn der Projektleitung die Kosten des Durchgangs deutlich übersteigen, mit einem ROI größer als 3 (Kriterium K6 aus Kapitel 1).

3. Was verglichen wird

Zwei feste Bausteine

Plattform n8n. n8n ist ein Werkzeug, mit dem sich Abläufe aus fertigen Bausteinen zusammensetzen und automatisieren lassen. Der Kurs der MSIT gibt es als Plattform vor, andere Automatisierungsplattformen vergleichen wir deshalb nicht. Die Wahl lässt sich aber auch fachlich begründen: Der Ablauf ist in n8n als Schaubild sichtbar und für die Projektleitung nachvollziehbar, Anbindungen an E-Mail, Google Drive, Google Sheets und Slack sind fertig vorhanden, für eigene Logik gibt es Programmschritte, und ein Baustein zum Unkenntlichmachen sensibler Angaben (Guardrails) ist bereits enthalten. Eine Eigenentwicklung in Python oder JavaScript müsste all das selbst bauen und pflegen, was ein Team ohne eigene IT-Abteilung dauerhaft belastet.

Sprachmodell Gemini 2.5 Flash. Der Kursanbieter stellt über OpenRouter, eine Plattform, die Zugang zu Sprachmodellen verschiedener Anbieter vermittelt, einen Zugang bereit, der nur dieses Modell freigibt. Google beschreibt es auf seiner Modellseite als Modell mit gutem Verhältnis von Preis und Leistung für schnelle, häufige Aufgaben, die Schlussfolgerungen verlangen. Ein Vergleich verschiedener Modellanbieter findet deshalb nicht statt. Das Modell ist im Ablauf ein austauschbarer Schritt, der Test lässt sich später mit jedem anderen Modell wiederholen.

Drei Aufbauvarianten

Variante	Aufbau	Gedanke dahinter
V1 Cloud-Modell	n8n macht die Anfrage mit dem Guardrails-Baustein unkenntlich und lädt den Vertrag des Kunden aus Google Drive. Gemini 2.5 Flash ordnet ein, prüft gegen den Vertragstext und zitiert die Vertragsstelle wörtlich. Programmschritte prüfen das Zitat, lesen das Kontingentkonto und rechnen Rest und höchstmöglichen Verbrauch. Die Projektleitung gibt frei	Das Modell liest und versteht Freitext, alles Verbindliche liegt bei Regeln und Menschen
V2 Regelbasiert ohne KI	Gleiche Umgebung und Freigabe, aber ohne Sprachmodell. Einordnung und Vertragsabgleich laufen über Schlüsselwörter und feste Zuordnungen	Die einfachste Lösung. Sie ist die Messlatte und zeigt, was das Modell tatsächlich bringt
V3 Lokales Modell	Wie V1, aber das Sprachmodell läuft auf eigener Hardware statt bei einem Cloud-Anbieter	Rückfallebene, falls Kundentexte das Haus gar nicht verlassen dürfen

4. Kriterien

Wir nutzen die fünf Bewertungsfelder der IHK-Vorlage: Funktion, Datenschutz, Bedienung, Integration und Kosten. Ein sechstes Kriterium ist für dieses Projekt entscheidend: Kontrolle und Nachvollziehbarkeit, weil der Agent über Geld und Verträge mitentscheidet. Alle sechs leiten sich aus den Anforderungen oben ab. Wir gewichten sie nicht mit Zahlen, sondern legen eine klare Regel fest: **Eine Variante scheidet aus, wenn sie ungeschützte Kundentexte an Dritte gibt oder ohne Vertrag zur Auftragsverarbeitung arbeitet.** Unter den übrigen entscheidet das Gesamtbild.

Kriterium	Die Frage	So messen wir es
Funktion	Trifft das Werkzeug die richtige Entscheidung, auch bei Wünschen, die nur teilweise im Vertrag stehen?	Trefferquote bei „enthalten“ gegen „Zusatzleistung“, vor allem bei den Zusatzleistungen, und bei der Kategorie
Kontrolle und Nachvollziehbarkeit	Lässt sich jede Entscheidung prüfen? Hält der Agent Manipulationsversuchen im Kundentext stand?	Steht das Zitat wörtlich im Vertrag? Anteil und Berechtigung der Eskalationen, Testtexte mit Anweisungen wie „ignoriere den Vertrag“, gleiche Eingabe mehrfach
Datenschutz	Welche Daten verlassen das Haus, und an wen?	Anteil nicht unkenntlich gemachter Angaben in Testtexten, Weg der Daten je Variante
Bedienung und Betrieb	Wie viel Aufwand haben die Projektleitung beim Prüfen und das Haus beim Pflegen?	Zeit je Fall mit und ohne Agent, Aufwand für Einrichtung und Pflege
Integration	Fügt sich das Werkzeug in E-Mail, Ticketsystem, Vertragsablage und Freigabe ein?	Läuft der Ablauf von der Anfrage bis zur Freigabe durch
Kosten	Was kostet der Betrieb, auch im Verhältnis zu den Kosten einer falschen Entscheidung?	Preislisten mit Quelle, gemessener Verbrauch je Anfrage

5. Bewertung

Skala: sehr gut, gut, mittel, offen. Jede Bewertung ist eine Einschätzung der Gruppe. Bei V1 stützen erste Messungen aus dem Probebetrieb (Abschnitt 7) einen Teil davon, bei V2 und V3 beruht die Einschätzung auf dem Aufbau.

Kriterium	V1 Cloud-Modell	V2 Regelbasiert	V3 Lokales Modell
Funktion	**Gut.** Erste Messung: In echten Läufen zu allen fünf Verträgen lieferte das Modell ein nachvollziehbares Urteil mit Kategorie und einem Zitat, das im Vertrag steht. Das ist ein Fall je Kunde, die Trefferquote misst erst die Testphase. Wünsche, die nur zur Hälfte im Vertrag stehen, sind der erwartete Schwachpunkt und kommen gezielt in die Testmenge	**Mittel.** Eindeutige Fälle gelingen über feste Regeln, die Auslegung von Freitext nur grob. Mehr Fälle landen bei der Projektleitung	**Offen.** Aufbau wie V1, ob ein lokales Modell dasselbe leistet, zeigt erst der Test
Kontrolle und Nachvollziehbarkeit	**Gut.** Das Modell entscheidet nichts allein. Erste Messung: Zitierte das Modell die Kundenanfrage statt des Vertrags oder ein erfundenes Zitat, ging der Fall automatisch an die Projektleitung. Grenze: Ein echtes Zitat belegt die Herkunft, nicht zwingend das Urteil, deshalb gibt die Projektleitung jeden Vorschlag frei. Bei zwei Läufen desselben Falls blieb das Urteil gleich, die genannte Fundstelle wich ab	**Sehr gut.** Jede Regel ist einzeln nachvollziehbar, gleiche Eingabe ergibt gleiche Ausgabe. Ohne Sprachmodell gibt es niemanden, der eine Anweisung im Kundentext befolgen könnte	**Gut.** Wie V1

Kriterium	V1 Cloud-Modell	V2 Regelbasiert	V3 Lokales Modell
Datenschutz	**Mittel.** Erfüllt die Ausschlussregel: Nur unkenntlich gemachter Text verlässt das Haus, und für den echten Betrieb wird ein Vertrag zur Auftragsverarbeitung mit dem Modellanbieter vorausgesetzt. Erste Messung: E-Mail, Telefon, Kontonummer und Web-Adresse wurden vollständig unkenntlich gemacht	**Sehr gut.** Es verlässt nichts das Haus	**Sehr gut.** Der Text bleibt in der eigenen Umgebung
Bedienung und Betrieb	**Gut.** Die Projektleitung prüft einen fertigen Vorschlag mit Begründung. Erste Messung: rund 5 Sekunden je Durchlauf. Am Modell selbst fällt kaum Pflege an, das übernimmt der Anbieter	**Mittel.** Das Regelwerk wächst mit jedem Vertrag und muss gepflegt werden	**Mittel.** Ein eigener Modellserver muss betrieben werden, und das Haus hat keine IT-Abteilung
Integration	**Gut.** Erste Messung: Vertragsabruf aus Google Drive, Unkenntlichmachen, Modellaufruf, Prüfung, Kontingentkonto und Protokoll laufen durchgehend. Der Eingang läuft im Probebetrieb über eine Testschnittstelle. Anbindung an das Ticketsystem und Freigabe folgen im nächsten Bauschritt	**Gut.** Wie V1, mit einer Schnittstelle weniger	**Mittel.** Wie V1, zusätzlich muss n8n den lokalen Server erreichen
Kosten	**Gut.** Erste Messung: rund 0,1 US-Cent je Anfrage (Abschnitt 6)	**Offen.** Keine Modellkosten, aber Aufwand für Aufbau und Pflege der Regeln, dessen Höhe noch nicht bekannt ist	**Offen.** Keine Gebühr je Anfrage, aber Hardware, Strom und Betrieb

6. Kosten

Die Preise wurden am 20.10.2026 bei den Anbietern geprüft (n8n.io/pricing, docs.n8n.io, ai.google.dev, openrouter.ai). Beträge in US-Dollar stehen so, wie der Anbieter sie nennt.

Baustein	Preis	Hinweis
n8n Cloud, Starter	20 EUR im Monat bei jährlicher Abrechnung	2.500 Ausführungen im Monat
n8n Cloud, Pro	50 EUR im Monat bei jährlicher Abrechnung	10.000 Ausführungen im Monat
n8n Community Edition	**kostenlos bei eigenem Betrieb**	**Unsere Wahl:** n8n läuft lokal auf einem vorhandenen Rechner im Haus, ohne Lizenz- oder Cloudkosten. Die Lizenz erlaubt die Nutzung für interne Geschäftsabläufe. Die Cloud-Pläne oben dienen nur zum Vergleich
Gemini 2.5 Flash	0,30 USD je 1 Mio. Eingabe-Tokens, 2,50 USD je 1 Mio. Ausgabe-Tokens	Tokens sind die Texteinheiten, nach denen Sprachmodelle abgerechnet werden, meist Wortteile aus wenigen Zeichen. Im Kurs über den Zugang der MSIT ohne eigene Kosten

Gemessener Verbrauch: In einem echten Lauf brauchte eine Anfrage für Einordnung und Vertragsprüfung zusammen rund 1.840 Tokens Eingabe und rund 200 Tokens Ausgabe. Das sind nach Preisliste etwa 0,001 USD, also ein Zehntel Cent je Anfrage. Wie viele Anfragen im Monat anfallen, ist nicht gemessen. Selbst bei 2.500 Anfragen lägen die Modellkosten bei rund 2,50 USD im Monat. Die Länge hängt vom Vertrag ab, ein etwas höherer Betrag ist möglich.

Wirtschaftlichkeit je Durchgang (K6): Weil n8n lokal ohne Lizenzkosten läuft, kostet ein Durchgang nur den Modellaufruf von rund 0,1 US-Cent. Dem steht der Arbeitslohn gegenüber, den die Projektleitung heute für die manuelle Prüfung derselben Anfrage aufwendet. Wir setzen dafür bewusst den Lohn an und nicht den Stundensatz von 190 EUR, den Nordlicht Kunden für Senior-Leistungen berechnet:

Rechenschritt	Wert	Grundlage
Bruttogehalt Projektleitung	60.000 bis 75.000 EUR im Jahr	Gehaltsportale für IT-Projektleitung und Senior-Entwicklung (jobvector, jobjump, Indeed), angepasst an ein kleines Softwarehaus
plus Arbeitgeberanteil Sozialversicherung	rund 21 %	Lohnnebenkosten 2026 laut Lohn- und Steuerratgebern
geteilt durch Arbeitsstunden im Jahr	rund 1.680 Stunden	Annahme: 40 Stunden je Woche abzüglich Urlaub, Feiertage und Krankheit
Arbeitslohn je Stunde	**rund 43 bis 54 EUR**	60.000 × 1,21 / 1.680 bis 75.000 × 1,21 / 1.680

Jede eingesparte Minute ist damit rund 0,72 bis 0,90 EUR wert, ein Durchgang kostet rund 0,1 US-Cent. Kapitel 5 rechnet den ROI je Durchgang als eingesparten Arbeitslohn abzüglich der Kosten des Durchgangs, geteilt durch die Kosten des Durchgangs. Die Zeit für den manuellen Vorgang messen wir per Stoppuhr an der Testmenge.

Die Kosten je Variante im Überblick. Wo noch kein Betrag bekannt ist, steht eine Einschätzung des Aufwands. Den Aufwand für Einrichtung und Pflege schreiben wir beim Bau mit und bewerten ihn in Kapitel 5 ebenfalls mit dem Arbeitslohn der Beteiligten.

Kostenart	V1 Cloud-Modell	V2 Regelbasiert	V3 Lokales Modell
Lizenz und Nutzung	keine, n8n läuft lokal	keine, n8n läuft lokal	keine, n8n läuft lokal
Modell und API	rund 0,1 Cent je Anfrage, gemessen	keine	keine Gebühr, dafür eigene Hardware, Betrag offen
Einrichtung und Integration	gering, der Ablauf läuft bereits	mittel, Regeln für fünf Verträge schreiben	hoch, Server und Modell einrichten
Betrieb und Pflege	gering	mittel, Regeln wachsen mit jedem Vertrag	hoch, Updates und Ausfälle selbst tragen
Schulung und Prozessänderung	gering: Die Projektleitung prüft Vorschläge statt selbst zu suchen, die Buchhaltung bucht wie bisher	wie V1	wie V1, zusätzlich Fachwissen für den Serverbetrieb

Kostenart	V1 Cloud-Modell	V2 Regelbasiert	V3 Lokales Modell
Kosten von Fehlern	Eine übersehene Zusatzleistung bedeutet unbezahlte Entwicklerarbeit, schon eine Kleinstveränderung darf laut Vertrag bis zu 2.500 EUR Aufwand haben. Eine zu Unrecht berechnete Leistung darf nach den Verträgen nicht abgerechnet werden und belastet die Kundenbeziehung. Eine übersehene Fehlermeldung gefährdet vertragliche Fristen. Eine einzige erkannte Zusatzleistung von 1.000 EUR entspricht rechnerisch den Modellkosten von rund einer Million Anfragen. Entscheidend ist deshalb nicht der Preis je Anfrage, sondern die Trefferquote		

7. Erste Messungen

Für V1 gibt es einen Probebetrieb in n8n mit erfundenen Daten und den fünf Verträgen in Google Drive. Von rund 50 Testläufen liefen 17 echt gegen Google Drive und das Sprachmodell, die übrigen mit vorgegebenen Modellantworten, um gezielt Fehlerfälle zu prüfen. Das ist ein erster Testbeleg, noch nicht die Messung an der Testmenge der Testphase.

Gemessen	Ergebnis
Zuordnung Kunde zu Vertrag	Alle fünf Kunden laden den richtigen Vertrag
Urteil des Agenten	Kunde A: Zusatzleistung der Kategorie B. Kunde B und Kunde C: jeweils Zusatzleistung der Kategorie A. Kunde D: im Vertrag enthalten. Kunde E: Zusatzleistung der Kategorie C. Jedes Urteil mit einem Zitat, das im Vertrag steht. Je Kunde ein Fall, die Trefferquote folgt in der Testphase
Unkenntlich machen	E-Mail, Telefon, Kontonummer (mit und ohne Leerzeichen) und Web-Adresse vollständig unkenntlich
Laufzeit und Kosten	rund 5 Sekunden und rund 0,1 US-Cent je Anfrage
Kontingent	Bei Kunde C waren noch 8 von 60 Stunden übrig. Eine Kleinstveränderung kann dort bis zu 10,6 Stunden kosten (1.000 EUR geteilt durch 95 EUR, aufgerundet), deshalb ging der Fall an die Projektleitung. Bei Kunde D und E reichte das Kontingent, bei Kunde A erschien ein Hinweis auf das Seitenkontingent. Nach einer von Hand eingetragenen Testbuchung ging dieselbe Anfrage bei Kunde D an die Projektleitung, ebenso bei Kunde E mit abgelaufenem Zeitraum
Absicherung	Leere oder ungültige Modellantworten, unsichere Einstufungen, erfundene Zitate, ein unbrauchbarer Vertrag und eine ungültige Kundenkennung gingen jeweils an die Projektleitung, statt still durchzulaufen

Die Tests haben zwei Fehler im eigenen Aufbau aufgedeckt, die behoben sind: Ein Baustein verwarf Felder, sodass ein leerer Text beim Modell angekommen wäre, und die erste Prüfung der Vertragsstelle war bei kurzen Angaben wirkungslos. Sie wurde durch die Prüfung eines wörtlichen Zitats ersetzt. Genau dafür ist ein früher Probebetrieb da.

8. Testphase

Die eigentliche Testphase folgt mit der Erfolgskontrolle in Kapitel 5. Alle drei Varianten laufen mit denselben Fällen:

- **Testmenge:** rund 60 selbst erstellte Kundenäußerungen zu den fünf Kunden, von Hand eingeordnet, mit schwierigen Fällen: grenzwertige Formulierungen, Verneinungen, Wünsche, die nur zur Hälfte im Vertrag stehen, zwei Wünsche in einer Nachricht.
- **Zusätzlich:** Texte mit eingebauten Kontaktdaten und Bankverbindungen sowie Texte mit Manipulationsversuchen.
- **Gemessen wird:** Trefferquote beim Urteil und bei der Kategorie, Zeit je Fall mit und ohne Agent, Anteil und Berechtigung der Eskalationen, Anteil nicht unkenntlich gemachter Angaben, Kosten je Anfrage. Die Zielwerte K1 bis K6 stehen in Kapitel 1.
- **Unabhängige Einordnung:** Zwei Gruppenmitglieder ordnen die Fälle getrennt ein. Die Testfälle schreibt nicht die Person, die den Agenten baut.

Weil Testfälle und Musterlösung aus derselben Gruppe stammen, fällt das Ergebnis eher günstig aus. Das halten wir im Bericht offen fest.

9. Zielkonflikte

Der wichtigste Zielkonflikt liegt zwischen **Datenschutz und Leistung**: V2 und V3 geben nichts nach außen, legen Freitext aber voraussichtlich schlechter aus als ein Cloud-Modell. V1 löst das, indem nur unkenntlich gemachter Text an einen vertraglich gebundenen Anbieter geht, nimmt aber in Kauf, dass überhaupt Text das Haus verlässt. Ein zweiter Konflikt besteht zwischen **Kontrolle über die Daten und Aufwand**: Je mehr im eigenen Haus läuft, desto mehr Pflege fällt in einem Team ohne IT-Abteilung an. V1 verlagert diesen Aufwand an den Anbieter und macht das Haus von dessen Modellen abhängig. Der dritte Konflikt betrifft **Nachvollziehbarkeit und Flexibilität**: Regeln sind prüfbar und liefern immer dasselbe, decken aber nur Vorhergesehenes ab. Ein Modell versteht auch unerwartete Formulierungen, liefert aber nicht jedes Mal exakt dieselbe Antwort, wie der Probebetrieb gezeigt hat. V1 fängt das ab, indem alles Verbindliche bei Regeln und Menschen bleibt.

10. Vorläufige Empfehlung

Wir empfehlen **V1, n8n mit Gemini 2.5 Flash**.

- Sie passt zum Kern der Aufgabe, Freitext im Kundenwunsch gegen Vertragstext abzugleichen.
- Der Aufbau ist auf Sicherheit gebaut: Das Modell schlägt vor, Regeln rechnen, ein Programmschritt prüft das Zitat, die Projektleitung gibt frei. Im Probebetrieb haben diese Kontrollen die Fehler gefangen, die wir ihnen gezielt gestellt haben.
- Sie läuft bereits durchgehend mit allen fünf Verträgen, in rund 5 Sekunden je Anfrage.
- Die Kosten liegen gemessen bei rund einem Zehntel Cent je Anfrage und sind gegenüber einer einzigen übersehenen Zusatzleistung vernachlässigbar.
- Das Modell steht im Kurs zur Verfügung und lässt sich später austauschen.

V2 bauen wir als einfache Vergleichsbasis nach und messen sie mit. Sie zeigt, was das Modell über feste Regeln hinaus bringt. V3 bleibt die Rückfallebene, falls sich das Unkenntlichmachen oder der Datenweg als nicht ausreichend erweisen. Für einen späteren echten Betrieb würden wir zusätzlich neuere Modelle testen, der Ablauf ist dafür vorbereitet.

Noch festzulegen sind die Schwellenwerte für die Eskalation. Die endgültige Auswahl und den Einsatzplan begründen wir in Kapitel 4.