Kapitel 3: KI-Tools nachvollziehbar vergleichen

Sprint 1, Change-Request-Agent für ein fiktives Softwarehaus. Stand 2026-10-20.

1. Worum es geht

Ein kleines fiktives Softwarehaus mit neun Mitarbeitenden baut KI-Einstiegs-Automatisierungen für kleine und mittlere Unternehmen. Seine Kunden äußern während des Projekts oder im Wartungsvertrag laufend Wünsche. Jedes Mal muss geklärt werden, ob der Wunsch schon im Vertrag steht oder als Zusatzleistung extra bezahlt wird. Das bleibt an der Projektleitung hängen, die zugleich Senior-Entwicklerin oder Senior-Entwickler ist, Kunden betreut und Demos vorbereitet.

Ein KI-Agent soll diese Arbeit vorbereiten. Er übernimmt drei Tätigkeiten, ein Mensch gibt jeden Fall frei:

1. **Schwärzen:** Personenbezogene Angaben werden aus der Kundenäußerung entfernt, bevor ein Modell den Text sieht.
2. **Klassifizieren:** Der Agent ordnet die Äußerung ein: Fehlermeldung, Überlegung, Wunsch, Auftrag oder Sonstiges.
3. **Entscheiden:** Bei Wünschen und Aufträgen schlägt er vor, ob sie im Vertrag enthalten oder eine Zusatzleistung sind, mit der passenden Vertragsstelle, einer kurzen Begründung und einem Sicherheitswert. Zugleich prüft er, ob das Kontingent des Kunden noch reicht, denn „im Vertrag enthalten“ gilt nicht unbegrenzt. Der Preis wird nicht vom Modell geschätzt, sondern nach einer festen Regel berechnet.

In diesem Kapitel wird verglichen, mit welchen Werkzeugen sich das am besten umsetzen lässt. **Für die empfohlene Variante V1 liegen erste Messungen aus einem Probebetrieb vor** (Abschnitt „Erste Messungen“). Die Varianten V2 und V3 sind noch nicht gebaut, ihre Bewertungen sind begründete Einschätzungen, die wir in der Testphase überprüfen. Belegt sind außerdem die Preise.

2. Was der Agent können muss

Die Anforderungen ergeben sich aus dem Alltag des Softwarehauses:

- Der Agent darf keine personenbezogenen Daten verarbeiten. Kundentexte werden vorher unkenntlich gemacht.
- Er ordnet jede Äußerung richtig ein. Fehlermeldungen und Reklamationen sortiert er aus und leitet sie weiter, sie dürfen nicht verloren gehen.
- Bei Wünschen und Aufträgen nennt er die passende Vertragsstelle, die Kategorie der Änderung, eine Begründung und einen Sicherheitswert.
- Er kennt das Kontingent jedes Kunden (Stunden, Euro oder Seiten laut Vertrag) und legt es zusammen mit einer groben Schätzung des Verbrauchs dazu. Reicht der Rest nicht mehr, geht der Fall an die Projektleitung. Der Agent liest das Kontingentkonto nur. Gebucht wird erst nach dem Bau mit der tatsächlichen Zahl, von Hand.
- Der Preis kommt aus einer festen Regel. Bei Unsicherheit und bei Zusatzleistungen entscheidet immer ein Mensch. Der Agent schreibt nie selbst an Kunden und verschickt keine Angebote.
- Er arbeitet mit dem, was das Haus schon nutzt: Mail, Ticketsystem und die Verträge. Die Freigabe läuft über Slack oder Mail.

- Er muss in einem Haus mit neun Mitarbeitenden ohne eigene IT-Abteilung betreibbar sein und die Projektleitung entlasten, nicht zusätzlich belasten.
- Neue Vertragsarten sollen ohne Umbau dazukommen können. Wir arbeiten mit fünf Beispielverträgen.
- Der Nutzen soll die Kosten deutlich übersteigen. Das Ziel im Projektplan ist ein ROI größer als 3, der Rechenweg folgt in der Auswertung.

3. Was verglichen wird

Zwei Bausteine stehen fest. Als Plattform dient n8n, ein Werkzeug zum Verbinden und Automatisieren von Abläufen. Sie ist im Kurs der MSIT vorgegeben. Als Sprachmodell nutzen wir Gemini 2.5 Flash von Google. Der Kursanbieter MSIT stellt dafür einen Zugang über die Plattform OpenRouter bereit, der nur dieses Modell freigibt. Google beschreibt es als Preis-Leistungs-Modell für schnelle, häufige Aufgaben, die Schlussfolgern verlangen. Ein Vergleich verschiedener Anbieter findet deshalb nicht statt. Das Modell bleibt im Ablauf ein austauschbarer Schritt, sodass sich der Test später mit einem anderen Modell wiederholen lässt.

Verglichen werden drei Aufbauvarianten:

Variante	Aufbau	Gedanke dahinter
V1 Cloud-Modell	n8n schwärzt die Anfrage mit seinem Guardrails-Baustein (feste Regeln für E-Mail, Telefon, IBAN, URL) und holt den Vertrag aus Google Drive. Gemini 2.5 Flash ordnet ein, prüft gegen den Vertragstext und nennt ein wörtliches Zitat. Ein Programmschritt kontrolliert, ob das Zitat wirklich im Vertrag steht, und der Preis wird nach Regel berechnet. Ein weiterer Programmschritt liest das Kontingentkonto des Kunden (eine Tabelle in Google Sheets) und rechnet Rest und höchsten Verbrauch der Änderung aus. Dann gibt ein Mensch per Slack oder Mail frei	Unser Wunschaufbau: Das Modell liest und versteht Freitext, alles Verbindliche liegt bei Regeln und Menschen
V2 Regelbasiert	gleiche Umgebung und Freigabe, aber ohne Sprachmodell. Klassifizieren und Vertragsabgleich laufen über Schlüsselwörter und feste Zuordnung	Die einfachste Lösung. Sie dient als Messlatte und zeigt, was das Modell wirklich bringt
V3 Lokales Modell	wie V1, aber das Sprachmodell läuft auf eigener Hardware statt bei einem Cloud-Anbieter	Rückfallebene für den Fall, dass Daten das Haus gar nicht verlassen dürfen

Für die drei Tätigkeiten gibt es unterschiedliche Möglichkeiten. Die erste Einschätzung:

Tätigkeit	Möglichkeiten	Erste Einschätzung
Schwärzen	feste Regeln, ein KI-Modell in der eigenen Umgebung, beides zusammen	Regeln zuerst: Sie laufen ohne Modell und liefern immer dasselbe. n8n bringt dafür einen fertigen Baustein mit (Guardrails). Gemessen erkennt er E-Mail-Adressen und den Hauptteil von Telefonnummern von selbst, bei einer IBAN mit Leerzeichen und bei Vorwahlen ließ er Reste stehen. Mit drei eigenen Mustern (IBAN, Telefon, URL) im selben Baustein war der Testtext vollständig geschwärzt. Namen und Orte erkennt er nicht, dafür käme ein lokales KI-Modell als Ergänzung in Frage. Ein Cloud-Modell scheidet aus, weil der ungeschwärzte Text dafür das Haus verlassen müsste
Klassifizieren	Regeln, Cloud-Modell, lokales Modell	Der Unterschied zwischen „wäre schön, wenn“ und „bitte setzt um“ steckt in der Formulierung. Ein Sprachmodell erfasst das voraussichtlich besser als Stichwortregeln
Entscheiden	Regeln, Cloud-Modell, lokales Modell	Freitext gegen Vertragstext auszulegen ist die Stärke eines Sprachmodells. Der Preis bleibt eine Regel, die Freigabe ein Mensch

4. Nach welchen Kriterien verglichen wird

Wir nutzen die fünf Bewertungsfelder, die für einen Tool-Vergleich üblich sind: Funktion, Datenschutz, Bedienung, Integration und Kosten. Dazu kommt ein sechstes, das für dieses Projekt entscheidend ist: Kontrolle und Nachvollziehbarkeit, weil der Agent über Geld und Verträge mitentscheidet.

Kriterium	Die Frage	Wie wir es in der Testphase messen
Funktion	Trifft das Werkzeug die richtige Entscheidung, auch bei Wünschen, die nur teilweise im Vertrag stehen? Kommen neue Vertragsarten ohne Umbau dazu?	Trefferquote bei „im Vertrag“ gegen „Zusatzleistung“, besonders bei den Zusatzleistungen, die nicht übersehen werden dürfen; Trefferquote bei der Kategorie; Testlauf mit allen fünf Beispielverträgen
Kontrolle und Nachvollziehbarkeit	Lässt sich jede Entscheidung prüfen? Was passiert bei Manipulationsversuchen im Kundentext?	Steht das Zitat des Modells wörtlich im Vertrag? Wie oft eskaliert der Agent bei Unsicherheit, und wie oft liegt er dann falsch? Testtexte mit Anweisungen wie „ignoriere den Vertrag“; gleiche Eingabe mehrfach
Datenschutz	Bleiben personenbezogene Daten im Haus?	Anteil der Angaben, die in Testtexten mit eingebauten Namen und Kontaktdaten nicht geschwärzt wurden; Weg der Daten je Variante
Bedienung	Wie viel Aufwand haben die Projektleitung beim Prüfen und das Haus beim Pflegen?	Zeit je Fall mit und ohne Agent; Aufwand für Einrichtung und Pflege, beim Bau mitgeschrieben
Integration	Fügt sich das Werkzeug in Mail, Ticketsystem, Verträge und Freigabe ein?	Läuft der Ablauf von der Anfrage bis zur Freigabe durch, ja oder nein
Kosten	Was kostet der Betrieb, auch gegenüber den Kosten einer falschen Entscheidung?	Preislisten mit Quelle; Kosten je Anfrage in der Testphase

5. Bewertung

Skala: sehr gut, gut, mittel, offen (noch nicht einschätzbar). Für V1 stützen sich die Einschätzungen zum Teil auf erste Messungen (Abschnitt „Erste Messungen“). Bei V2 und V3 sind es Einschätzungen auf Basis des Aufbaus, die die Testphase nachprüft.

Kriterium	V1 Cloud-Modell (Gemini 2.5 Flash)	V2 Regelbasiert	V3 Lokales Modell
Funktion	**Gut, erste Läufe sind plausibel.** In echten Läufen zu allen fünf Verträgen lieferte das Modell ein nachvollziehbares Urteil mit Kategorie, Fundstelle und einem Zitat, das im Vertrag steht. Die Trefferquote ist noch nicht an einer Musterlösung gemessen. Wünsche, die nur zur Hälfte im Vertrag stehen, sind der erwartete Schwachpunkt und kommen gezielt in die Testmenge	**Mittel.** Eindeutige Fälle gehen über feste Regeln, die Auslegung von Freitext nur grob. Mehr Fälle gehen in die Eskalation an den Menschen	**Offen.** Aufbau wie V1. Ob ein lokales Modell dasselbe leistet, zeigt der Test

Kriterium	V1 Cloud-Modell (Gemini 2.5 Flash)	V2 Regelbasiert	V3 Lokales Modell
Kontrolle und Nachvollziehbarkeit	**Gut.** Das Modell entscheidet nichts allein: Ein Mensch gibt jeden Fall frei, der Preis kommt aus einer Regel, ein Programmschritt prüft, ob ein wörtliches Zitat des Modells im Vertrag steht. Das hat im Probebetrieb gewirkt: Zitierte das Modell die Kundenanfrage statt des Vertrags, ging der Fall automatisch an die Projektleitung, ebenso bei erfundenen Zitaten und ungültigen Werten. Grenze: Das Zitat belegt die Herkunft, nicht dass es das Urteil stützt, deshalb prüft ein Mensch jeden Fall. Die Ausgabe ist nicht bei jedem Lauf identisch: Bei demselben Fall nannte das Modell in zwei Läufen dasselbe Urteil mit unterschiedlicher Fundstelle. Manipulationsversuche im Kundentext sind gegen das echte Modell noch nicht getestet	**Sehr gut.** Jede Regel ist einzeln nachvollziehbar, gleiche Eingabe ergibt gleiche Ausgabe, Manipulation eines Modells ist ausgeschlossen	**Gut.** Wie V1
Datenschutz	**Mittel.** Es verlässt nur geschwärzter Text das Haus, und zwar über OpenRouter zum Modellanbieter. Gemessen werden E-Mail, Telefon, IBAN und URL vollständig geschwärzt, Namen und Orte bleiben dabei lesbar. Im Kurs fließen nur erfundene Daten. Jeder Anbieter hat eigene Regeln zu Speicherung und Training, OpenRouter erlaubt, Anbieter auszuschließen, die auf Daten trainieren. Welche Einstellungen am Kurs-Zugang gelten, ist nicht geprüft. Für echte Kundendaten wäre vorher ein eigener Zugang mit geklärter Datenverarbeitung nötig	**Sehr gut.** Es verlässt nichts das Haus	**Sehr gut.** Der Text verlässt die eigene Umgebung nicht
Bedienung	**Gut.** Der Ablauf ist in n8n sichtbar, die Projektleitung prüft nur einen fertigen Vorschlag mit Begründung. Ein Durchlauf dauerte im Probebetrieb rund 5 Sekunden. Am Modell selbst fällt kaum Pflege an. Google führt Gemini 2.5 Flash als nicht abgekündigt, empfiehlt für neue Projekte aber neuere Modelle (Stand 2026-10-20)	**Mittel.** Das Regelwerk wächst mit jeder Vertragsart und muss gepflegt werden. Wer das in einem Haus mit neun Mitarbeitenden übernimmt, ist offen	**Mittel.** Ein eigener Modell-Server will betrieben werden (Hardware, Updates, Ausfälle), und das Haus hat keine IT-Abteilung
Integration	**Gut, größtenteils belegt.** Eingang, Vertragsabruf aus Google Drive, Schwärzen, Modellaufruf, Prüfung, Kontingentkonto und Protokoll laufen in n8n durchgehend (Probebetrieb mit allen fünf Verträgen). Es fehlt noch die Freigabe per Slack oder Mail, die bauen wir in Sprint 2	**Gut.** Wie V1, mit einer Schnittstelle weniger	**Mittel.** Wie V1, zusätzlich muss n8n den lokalen Server erreichen
Kosten	**Gut.** Im Kurs entstehen keine Modellkosten, im Betrieb sind es gemessen rund 0,1 US-Cent je Anfrage (siehe unten)	**Offen.** Keine Modellkosten, aber Aufwand für Aufbau und Pflege des Regelwerks	**Offen.** Keine Gebühr je Anfrage, aber Hardware, Strom und Betrieb

6. Was es kostet

Belegt, geprüft am 2026-10-20:

Baustein	Preis	Hinweis
n8n Cloud, Starter	20 € pro Monat bei jährlicher Abrechnung	2.500 Ausführungen pro Monat
n8n Cloud, Pro	50 € pro Monat bei jährlicher Abrechnung	10.000 Ausführungen pro Monat
n8n Community Edition	kostenlos bei Selbsthosting (Quelle docs.n8n.io)	Kosten entstehen nur für den eigenen Server. Einige Funktionen gehören zu den bezahlten Plänen, etwa Projekte, Single Sign-on und Versionsverwaltung mit Git. Die Lizenz erlaubt die Nutzung für interne Geschäftsabläufe
Gemini 2.5 Flash	0,30 US-Dollar je 1 Million Eingabe-Tokens, 2,50 US-Dollar je 1 Million Ausgabe-Tokens (einschließlich Denk-Tokens)	im Kurs über den OpenRouter-Zugang der MSIT ohne eigene Kosten; Preise laut ai.google.dev und openrouter.ai

Gemessener Verbrauch: In einem echten Probelauf (Kunde A) brauchte eine Anfrage zusammen für Klassifikation und Vertragsprüfung etwa 1.840 Tokens Eingabe und rund 200 Tokens Ausgabe. Nach der Preisliste sind das etwa 0,001 US-Dollar, also rund ein Zehntel Cent je Anfrage. Tausend Anfragen im Monat lägen damit bei rund 1 US-Dollar. Die Länge hängt vom Vertrag ab, und ob die Denk-Tokens des Modells in der Zählung enthalten sind, ist nicht sicher, der Betrag könnte also etwas höher liegen. Zum Vergleich: Eine einzige falsch als „im Vertrag" eingestufte Zusatzleistung bedeutet unbezahlte Entwicklerarbeit, und die ist deutlich teurer als dieses Modell.

7. Erste Messungen

Für V1 gibt es einen Probebetrieb in n8n mit erfundenen Daten und den fünf Beispielverträgen in Google Drive. Es waren rund 50 Testläufe, ein Teil davon echt gegen Drive und das Modell. Das ist noch keine Messung an der Testmenge der eigentlichen Testphase.

Was gemessen wurde	Ergebnis
Zuordnung Kunde zu Vertrag	Alle fünf Kunden laden die richtige Kurzfassung aus Google Drive
Urteil des Agenten	Kunde A, C und E: Zusatzleistung (Kategorie B, A, C). Kunde B: Zusatzleistung, Kategorie A. Kunde D: im Vertrag enthalten. Jedes Urteil mit einem Zitat, das im Vertrag steht. Es ist je ein Einzelfall, die Trefferquote ist offen
Schwärzen	E-Mail, Telefon, IBAN (mit und ohne Leerzeichen) und URL vollständig geschwärzt. Namen und Orte nicht
Laufzeit	rund 5 Sekunden je Anfrage
Verbrauch	rund 0,1 US-Cent je Anfrage (siehe Abschnitt Kosten)
Kontingent	Rest, Periode und höchster Verbrauch der Änderung werden im Programmschritt gerechnet, nicht vom Modell. Sechs echte Läufe: Kunde C (Rest 8 von 60 Stunden, höchstens 10,6) ging an die Projektleitung, D und E liefen durch, bei A (Seitenkontingent) erschien nur ein Hinweis. Mit einer eingetragenen Testbuchung ging dieselbe Anfrage bei D an die Projektleitung, ebenso bei E mit abgelaufener Periode
Absicherung	Leere oder ungültige Modellantworten, unsichere Einstufungen, erfundene Zitate, ein zu kurzer Vertrag und eine ungültige Kunden-ID gingen jeweils an die Projektleitung, statt still durchzulaufen (Tests mit vorgegebenen Antworten)

Die Tests haben auch zwei Fehler im eigenen Aufbau gezeigt, die inzwischen behoben sind: Ein Baustein verwarf Felder, sodass ein leerer Text beim Modell angekommen wäre, und die erste Prüfung

der Vertragsstelle war bei kurzen Angaben wirkungslos. Sie wurde durch die Prüfung eines wörtlichen Zitats ersetzt.

Nicht gemessen sind die Trefferquote an einer von Menschen eingeordneten Testmenge, die Varianten V2 und V3 und Manipulationsversuche gegen das echte Modell.

8. Wie wir testen

Die eigentliche Testphase findet in Sprint 3 statt. Alle drei Varianten laufen mit denselben Fällen:

- **Testmenge:** rund 60 selbst erstellte Kundenäußerungen zu zwei bis drei fiktiven Projekten, von Hand eingeordnet, mit schwierigen Fällen: grenzwertige Formulierungen, Verneinungen, Wünsche, die nur zur Hälfte im Vertrag stehen, und zwei Wünsche in einer Äußerung.
- **Zusätzlich:** Texte mit eingebauten personenbezogenen Angaben für den Schwärzen-Test und Texte mit Manipulationsversuchen.
- **Gemessen wird:** Trefferquote beim Vertragsurteil und bei der Kategorie, Zeit je Fall mit und ohne Agent, Anteil der Eskalationen und deren Fehlerquote, Anteil nicht geschwärzter Angaben, Kosten je Anfrage.
- **Unabhängige Einordnung:** Zwei Gruppenmitglieder ordnen die Fälle getrennt ein, die Testfälle schreibt nicht die Person, die den Agenten baut.
- **Entscheidungsregel:** Eine Variante scheidet aus, wenn sie den Datenschutz nicht einhält. Unter den übrigen entscheidet das Gesamtbild aus den anderen Kriterien.
- **Schwellen:** Wie gut „gut genug" ist, legen wir vor der Messung fest.

Ehrlich bleibt dabei: Testfälle und Musterlösung stammen aus derselben Gruppe, das Ergebnis fällt dadurch eher günstig aus. Das halten wir im Bericht fest.

9. Wo sich Ziele widersprechen

- **Datenschutz gegen Leistung:** V2 und V3 geben nichts nach außen, könnten aber Freitext schlechter auslegen als ein Cloud-Modell. Das ist die zentrale Frage der Testphase.
- **Kontrolle über die Daten gegen Aufwand:** Je mehr im eigenen Haus läuft, desto mehr Pflege fällt in einem kleinen Team an. V1 verlagert diesen Aufwand an den Anbieter und macht das Haus von dessen Modellen abhängig.
- **Nachvollziehbarkeit gegen Flexibilität:** Regeln sind prüfbar und wiederholbar, decken aber nur Vorhergesehenes ab. Ein Modell fängt unerwartete Formulierungen ab, liefert aber nicht jedes Mal exakt dasselbe (im Probebetrieb belegt: gleiches Urteil, aber unterschiedliche Fundstelle in zwei Läufen).

10. Ergebnis und Empfehlung

Wir empfehlen vorläufig **V1 mit Gemini 2.5 Flash.** Die Gründe:

- Sie passt zum Kern der Aufgabe: Freitext im Kundentext mit Vertragstext abgleichen.
- Der Aufbau ist auf Sicherheit gebaut. Das Modell schlägt vor, Regeln rechnen den Preis, ein Programmschritt prüft das Zitat im Vertrag, ein Mensch gibt frei. Im Probebetrieb haben diese Kontrollen die Fehler gefangen, die wir ihnen gestellt haben.
- Die Kosten liegen gemessen bei rund einem Zehntel Cent je Anfrage.

- Sie läuft bereits durchgehend: Alle fünf Verträge aus Google Drive wurden in echten Läufen geladen und geprüft, ein Durchlauf dauert rund 5 Sekunden.
- Das Modell steht im Kurs zur Verfügung und lässt sich später austauschen.

V2 wird als einfache Vergleichsbasis nachgebaut und mitgemessen. Sie zeigt, was das Modell über Regeln hinaus bringt. V3 bleibt Rückfallebene, falls Schwärzung oder Datenweg sich als nicht ausreichend erweisen. Für einen späteren echten Betrieb würden wir zusätzlich aktuellere Modelle testen, der Ablauf ist dafür vorbereitet. Die endgültige Auswahl begründen wir in der Einsatzplanung im nächsten Kapitel.

11. Noch offen

- Die Schwellen für „gut genug“ und der Rechenweg für den ROI, beides vor der Messung.
- Ob n8n in der Cloud oder selbst gehostet läuft.
- Die Trefferquote des Urteils an einer von Menschen eingeordneten Testmenge, und ob das Zitat das Urteil auch wirklich stützt (zweite Prüfung oder Testmenge).
- Die Höchstgrenze für den Verbrauch einer Änderung stammt aus dem Vertrag (Kategorie A). Wie genau der Agent den tatsächlichen Aufwand schätzen kann, zeigt die Testphase. Die Kontingentkonten enthalten bisher Beispieldaten.
- Ob für Namen und Orte, die der Guardrails-Baustein nicht erkennt, ein lokales KI-Modell hinzukommt, das entscheidet der Test.