Kapitel 4: Begründete Tool-Auswahl und Einsatzplanung

Nordlicht KI-Werkstatt GmbH · Stand 26.10.2026

Kapitel 3 hat drei Aufbauvarianten verglichen und V1 wurde entschieden. Dieses Kapitel begründet die endgültige Auswahl und beschreibt, wie der Agent bei der Nordlicht KI-Werkstatt eingeführt wird: mit welchen technischen Voraussetzungen, in welchen Systemen, mit welchen Datenschutzeinstellungen, mit welchem Personal und in welchem Zeitplan.

1. Begründete Auswahl

Wir wählen **V1: n8n mit dem Sprachmodell Gemini 2.5 Flash**. Die Auswahl folgt aus drei Quellen.

Grundlage	Was daraus für V1 spricht
Ziele aus Kapitel 1	Der teuerste Fehler ist eine übersehene Zusatzleistung (K1). Dafür muss der Agent Freitext gegen Vertragstext auslegen, auch bei Formulierungen, die niemand vorhergesehen hat. Das leistet ein Sprachmodell, eine feste Regel nicht.
Anforderungen aus Kapitel 3	V1 erfüllt die Ausschlussregel: Nur unkenntlich gemachter Text geht an das Sprachmodell. Alles Verbindliche liegt bei Regeln und Menschen: Ein Programmschritt prüft das Zitat, eine Regel rechnet Kontingent und Preis, die Projektleitung gibt jeden Vorschlag frei.
Ergebnisse des Vergleichs	V1 läuft im Probebetrieb bereits durchgehend mit allen fünf Verträgen, in rund 5 Sekunden und für rund 0,1 US-Cent je Anfrage. Die Kontrollen haben die Fehler gefangen, die wir ihnen gezielt gestellt haben.

V2, regelbasiert ohne KI, bauen wir nicht nach. Ob ein Kundenwunsch im Vertrag enthalten ist, hängt von der Bedeutung seiner Formulierung ab, und dieselbe Bedeutung lässt sich auf so viele Arten ausdrücken, dass feste Schlüsselwörter sie nicht zuverlässig erfassen, schon eine Verneinung wie „wir brauchen den Export nicht mehr" kehrt die Aussage um. Als Messlatte dient deshalb die Bearbeitung derselben Testfälle von Hand, die Kapitel 1 ohnehin als Ausgangswert festlegt.

V3, lokales Modell, bleibt die Rückfallebene, falls sich das Unkenntlichmachen oder der Datenweg als nicht ausreichend erweisen.

2. Technische Voraussetzungen

- **Rechner im Haus:** n8n läuft als kostenlose Community Edition in Docker auf einem vorhandenen Rechner. Er muss während der Arbeitszeit eingeschaltet sein, weil der Agent den Eingang jede Minute abfragt.
- **Internetzugang** für den Aufruf des Sprachmodells über OpenRouter und für die Anbindung an Postfach, Google Drive, Google Sheets und Slack.
- **Zugänge:** ein Zugriff von n8n auf das Postfach der Projektleitung (Lesen und Verschieben von Mails), auf die Vertragsablage in Google Drive und die Tabellen in Google Sheets sowie eine App im vorhandenen Slack-Workspace.
- **Daten:** je Kunde eine Kurzfassung des Vertrags in Google Drive, ein Kundenstamm in Google Sheets (Kunde, Absenderadressen, Vertragsdatei, Kontingentkonto) und je Kunde ein Kontingentkonto.

- **Eskalationsschwellen:** 0,6 für das Einordnen und 0,7 für die Vertragsprüfung. Sie gelten als Startwerte und werden erst festgeschrieben, wenn alle Tests ausgewertet sind (Kapitel 5).

3. Integration in bestehende Systeme

Der Agent fügt sich in die Werkzeuge ein, die Nordlicht bereits nutzt: E-Mail, Vertragsablage in Google Drive, Stundenkonten in Google Sheets und Slack für die interne Abstimmung.

1. **Eingang:** Die Projektleitung verschiebt eine Kundenmail in den Postfach-Ordner „Agent". Der Agent holt sie innerhalb einer Minute ab.
2. **Kunde zuordnen:** Der Kunde wird über die Absenderadresse im Kundenstamm bestimmt und nicht aus dem Text erraten. Ist der Absender unbekannt, wird die Mail abgelehnt und in den Ordner „Fehler" verschoben.
3. **Verarbeiten:** Unkenntlich machen, in einzelne Anliegen trennen, jedes Anliegen einordnen, Vertrag prüfen, Zitat und Kontingent kontrollieren, wie in Kapitel 1 beschrieben. Jedes Anliegen bekommt eine eigene Ticketnummer und eine eigene Nachricht in Slack. Danach wandert die Mail einmal in den Ordner „Verarbeitet".
4. **Weitergeben über Slack:** Fehlermeldungen gehen an den Kanal der Senior-Entwicklung, Fälle mit dem Urteil „enthalten" an die Senior-Entwicklung zur Umsetzung. Zusatzleistungen, unsichere Fälle und Eskalationen erscheinen als Freigabekarte mit Einordnung, Vertragsstelle, Kontingent und Kommentar/Begründung. Die Projektleitung gibt per Knopfdruck frei oder lehnt ab. Freigegebene Zusatzleistungen der Kategorien B und C gehen an den Vertrieb.
5. **Protokollieren:** Jeder Fall wird mit Einordnung, Urteil, Kategorie, Begründung und Freigabe festgehalten, ohne den Anfragetext.

Ausbaustufen, nicht Teil des ersten Einsatzes: Die Anbindung eines Ticketsystems als zweiter Eingang und die Freigabe per E-Mail als Rückfall, falls Slack nicht erreichbar ist. Beide lassen sich ergänzen, ohne den Ablauf zu ändern.

4. Datenschutzkonforme Konfiguration

Grundsatz: **Die Kundendaten bleiben in den Systemen des Unternehmens.** Postfach, Vertragsablage, Tabellen und Slack gehören zum Konto von Nordlicht, Zugriff haben nur die Mitarbeitenden, die den Fall bearbeiten. n8n läuft auf einem eigenen Rechner im Haus. Das einzige Element, das Kundentexte außerhalb des Unternehmens verarbeitet, ist das Sprachmodell. Deshalb setzt der Schutz genau dort an:

- E-Mail-Adressen, Telefon- und Kontonummern sowie Web-Adressen werden vor jedem Aufruf des Sprachmodells unkenntlich gemacht. Scheitert das, geht kein Text an das Modell.
- Die Absenderadresse dient nur der Zuordnung des Kunden. Sie geht weder an das Modell noch in das Protokoll.
- Beim Modellzugang ist die Datensammlung durch den Anbieter abgewählt. Vor dem Pilot wird ein Vertrag zur Auftragsverarbeitung mit dem Modellanbieter geschlossen.
- Der Kundentext gilt im Agenten als reine Daten. Anweisungen darin, etwa „ignoriere den Vertrag", werden nicht befolgt.
- Das Protokoll enthält keinen Anfragetext. Der Agent schreibt nie an Kunden, verschickt keine Angebote und bucht nichts auf Stundenkonten.

5. Personal und Rollen

Rolle	Aufgabe beim Agenten
Projektleitung	Betreut den Agenten fachlich und technisch: Sie gibt frei, pflegt Kundenstamm und Vertragskurzfassungen, passt Schwellen und Ablauf an und wertet das Protokoll aus. Das passt zu ihrer Rolle, sie ist zugleich Senior-Entwicklung.
Ein Senior-Entwickler	Vertritt die Projektleitung bei Urlaub und Krankheit in Freigabe und Grundpflege.
Senior-Entwicklung	Übernimmt Fehlermeldungen und die Umsetzung enthaltener Leistungen aus ihrem Slack-Kanal.
Vertrieb	Erhält freigegebene Zusatzleistungen der Kategorien B und C mit Vertragsstelle und entscheidet über Zusatzgeld.
Buchhaltung	Bucht nach der Umsetzung die tatsächlichen Stunden, wie bisher.
Geschäftsführung	Entscheidet bei Streit über die Auslegung eines Vertrags.

6. Schulung

- **Projektleitung:** Sie hat den Agenten mit aufgebaut und braucht keine eigene Schulung.
- **Vertretung:** Der vertretende Senior-Entwickler lernt, eine Freigabekarte zu lesen und zu entscheiden, den Kundenstamm nachzutragen und abgelehnte Mails im Ordner „Fehler“ zu prüfen. Wichtigster Inhalt: Das Zitat belegt die Herkunft, nicht zwingend das Urteil. Die Karte wird geprüft, nicht abgenickt.
- **Empfänger in Slack:** Senior-Entwicklung und Vertrieb bekommen eine kurze Einweisung, was die Nachrichten in ihrem Kanal bedeuten und was von ihnen erwartet wird.

7. Zeitplan mit Pilotphase

Phase	Dauer	Inhalt
Vorbereitung	2 Wochen	Vertrag zur Auftragsverarbeitung mit dem Modellanbieter, Kundenstamm und Vertragskurzfassungen einpflegen, Slack-Kanäle und Berechtigungen anlegen, Vertretung schulen, Empfänger einweisen
Pilot im Parallelbetrieb	mindestens 4 Wochen	Alle fünf Kunden von Anfang an. Die Projektleitung entscheidet jeden Fall zunächst selbst und gleicht ihr Ergebnis dann mit dem Vorschlag des Agenten ab. Das ist ein geringer Mehraufwand für eine überschaubare Zeit und liefert die Vergleichswerte aus dem echten Betrieb.
Entscheidung	nach dem Pilot	Vollbetrieb, wenn im Pilot K1 (Zusatzleistungen erkannt), K2 (mindestens 80 % richtige Kategorie) und K4 (keine Kontaktdaten beim Sprachmodell) erreicht sind. Sonst wird der Pilot verlängert und nachgebessert, etwa an Schwellen oder Anweisungen an das Modell.
Vollbetrieb	laufend	Die Projektleitung prüft nur noch den Vorschlag. Die Erfolgskontrolle beschreibt Kapitel 5.

8. Herausforderungen bei der Einführung

Herausforderung	Umgang damit
Die Kategorie schwankt bei gleicher Anfrage, im Probebetrieb beobachtet	Jeder Vorschlag wird freigegeben, der Parallelbetrieb zeigt, wie oft das vorkommt
Zu viel Vertrauen in den Vorschlag	Zitat und Begründung stehen immer auf der Karte, die Schulung betont die Prüfung, Kapitel 5 misst die Korrekturquote
Abwesenheit der Projektleitung	Geschulte Vertretung. Eine Freigabekarte wartet 8 Stunden, danach wird der Fristablauf protokolliert
Neuer Kunde oder neue Absenderadresse	Mail wird abgelehnt statt falsch zugeordnet, die Projektleitung trägt den Absender im Kundenstamm nach