Kapitel 5: Erfolgskontrolle, Kosten und Nutzen

Nordlicht KI-Werkstatt GmbH · Stand 27.10.2026

Kapitel 4 hat beschrieben, wie der Agent eingeführt wird. Dieses Kapitel prüft, ob er die Ziele aus Kapitel 1 erreicht, was er kostet und was er bringt, und wie nach der Einführung weiter gemessen wird. Jede Zahl ist gekennzeichnet: **gemessen** aus Tests oder Protokoll, **Annahme** von der Gruppe geschätzt, **offen**, wenn noch keine Daten vorliegen. Alle Firmen und Mails sind erfunden, die Tests liefen unter Laborbedingungen.

1. Von den Erfolgskriterien zur Kennzahl

Wir messen an denselben sechs Kriterien, die Kapitel 1 festgelegt hat. Verantwortlich für jede laufende Kontrolle ist die Projektleitung, die laut Kapitel 4 den Agenten betreut und das Protokoll auswertet.

Nr.	Kennzahl	Datenquelle	Intervall	Schwellenwert
K1	Anteil der Zusatzleistungen, die als Zusatzleistung vorgeschlagen oder eskaliert wurden	Stichprobe aus der Protokolltabelle, gegen den Vertrag nachgeprüft	wöchentlich	unter 95 %
K2	Anteil richtiger Kategorien bei nicht eskalierten Fällen	dieselbe Stichprobe	wöchentlich	unter 80 %
K3	Minuten je Äußerung mit Agent gegenüber von Hand	Stoppuhr im Pilot (Parallelbetrieb, Kapitel 4)	im Pilot	weniger als 50 % Ersparnis
K4	Kontaktdaten im Text, der an das Sprachmodell geht	n8n-Ausführungsdaten, Stichprobe	täglich	jeder Treffer
K5	Laufzeit je Anliegen bis zum Vorschlag	n8n-Ausführungsdaten	wöchentlich	über 1 Minute
K6	ROI je Durchgang	Modellkosten aus den Ausführungsdaten, Zeit aus K3	monatlich	ROI nicht größer als 3

2. Die Evaluation

Wir haben 60 verschiedene Test-Mails zu allen fünf Kunden geschickt: Fehlermeldungen, kleine und große Änderungswünsche, Änderungen von Kontaktdaten, unklare Mails, Überlegungen, Mails mit zwei Anliegen, einen Manipulationsversuch und Änderungen der Kategorie E. Die Ergebnisse wurden in den Slack-Karten und in der Protokolltabelle gesichtet und gegen die Verträge geprüft.

Runde	Mails	bestanden	teilweise	nicht bestanden	nicht aussagekräftig
1 (23.10.)	20	14	2	3	1
2 (dieselben 20, 24.10.)	20	14	3	2	1
3 (30 neue, 25.10.)	30	26	1	3	0
4 (10, je Testtyp eine, 26.10.)	10	9	0	1	0
5 (dieselben 10 nach den Änderungen, 26.10.)	10	10	0	0	0

„Teilweise“ heißt: Die Einordnung stimmt, aber ein Nebenziel wurde verfehlt, etwa ein Seitenkontingent, das nicht gerechnet wurde. Alle Werte sind **gemessen**. Die zwei in Runde 2 verfehlten Mails liefen am 26.10. mit dem aktuellen Workflow erneut und wurden richtig eingeordnet. Der Manipulationsversuch wurde nicht befolgt.

3. Wichtigste Fehler und Maßnahmen

Fehler	Wirkung	Maßnahme und Stand
Zwei Anliegen in einer Mail, eines geht verloren	Der teuerste Fehler: Eine Fehlermeldung, die zusammen mit einem Wunsch kam, ging an den Vertrieb statt an die Entwicklung. Die vertragliche Reaktionsfrist (bei Kunde B 4 Stunden) wäre ungenutzt verstrichen.	Ein vorgeschalteter Agent trennt die Mail in Anliegen, jedes läuft einzeln durch. Eingebaut, im Nachtest belegt.
Seitenkontingent nicht gerechnet	Ein Auftrag über 45 Seiten bei 20 übrigen Seiten ging als „enthalten" ohne Freigabe an die Entwicklung, also eine übersehene Zusatzleistung.	Das Sprachmodell gibt die Seitenzahl als eigenes Feld aus, eine Regel rechnet sie gegen den Rest. Eingebaut, in Runde 5 belegt. Rest: Der Begründungstext des Modells widerspricht dem Ergebnis teilweise noch.
Regeln aus dem Prompt nicht zuverlässig befolgt	Das Modell nannte trotz Verbot den Buchstaben einer Kategorie als Vertragsstelle, schätzte Beträge und hielt eine Verständnisfrage für eine Fehlermeldung.	Wichtige Regeln im Programmcode prüfen statt nur im Prompt, dazu ein Satz zu Verständnisfragen. Noch nicht umgesetzt.

> **Freigabeweg angepasst.** Zu Projektbeginn sollte die Projektleitung jeden Vorschlag freigeben (Kapitel 1). Im Verlauf der Entwicklung hat sich ein schlankerer Weg als effektiver erwiesen: Fehlermeldungen und als enthalten eingestufte Wünsche gehen ohne Freigabe an die Senior-Entwicklung, Sonstiges geht als Information an die Projektleitung. Eine Freigabekarte bekommen nur Zusatzleistungen, Eskalationen und unsichere Fälle. Grundlage ist K1: Seit dem Einbau der Seitenprüfung lief in den Tests keine Zusatzleistung mehr als enthalten durch. Die Projektleitung muss dadurch nicht mehr jeden Fall ansehen und wird stärker entlastet. Der Preis: Ein fälschlich als enthalten eingestufter Wunsch erreicht die Entwicklung ohne Prüfung. Die wöchentliche Stichprobe zu K1 kontrolliert genau diesen Weg.

4. Ergebnis je Kriterium

Kriterium und Zielwert	Ergebnis	Stand
K1 Zusatzleistungen erkannt, mindestens 95 %	100 %, 31 von 31 Mails mit Zusatzanteil, mit dem aktuellen Workflow	**gemessen**, erreicht
K2 Kategorie richtig, mindestens 80 %	94 %, 34 von 36 Mails, mehrere vertretbare Wege zugelassen	**gemessen**, erreicht
K3 Zeitersparnis, mindestens 50 %	69 bis 78 %: von Hand 13 bis 18 Minuten, mit Agent 4 Minuten (Vorschlag prüfen und freigeben)	**gemessen**, Stoppuhr im Pilot
K4 keine Kontaktdaten beim Sprachmodell	In einem Test mit E-Mail, Telefonnummer und IBAN erhielt das Modell nur Platzhalter, im Probebetrieb ebenso (Kapitel 3). Die Slack-Karte zeigt die Mail bewusst im Klartext, weil sie im Haus bleibt.	**gemessen**, erfüllt
K5 Vorschlag innerhalb einer Minute	2,2 bis 7,6 Sekunden, im Mittel 5,4 Sekunden (32 Läufe)	**gemessen**, erreicht
K6 ROI je Durchgang größer als 3	Ein Durchgang kostet rund 0,15 US-Cent, die eingesparte Arbeitszeit ist 7,28 bis 11,32 EUR wert. Der ROI liegt damit über 4.800.	Kosten **gemessen**, Nutzen **Annahme**, erreicht

5. Kosten

Kostenart	Posten	Betrag	Stand
Einmalig	Aufbau, Vertragsunterlagen, Tests, Einweisung	80 Stunden × 48,50 EUR = 3.880 EUR	**Annahme**

Kostenart	Posten	Betrag	Stand
Laufend	Pflege von Prompts, Regeln, Kundenstamm und Verträgen	5 Stunden im Monat = 2.910 EUR im Jahr	Annahme
Laufend	Sprachmodell Gemini 2.5 Flash: Einordnen und Vertragsprüfung	0,10 US-Cent je Anliegen im Mittel (0,14 mit, 0,04 ohne Vertragsprüfung)	gemessen
Laufend	Sprachmodell Gemini 2.5 Flash: Trennen einer Mail in Anliegen	0,05 US-Cent je Mail, zusammen also rund 0,15 US-Cent je Mail mit einem Anliegen	gemessen
Laufend	n8n, Lizenz und Hosting	keine, läuft lokal (Kapitel 3)	–
Risiko	Fehlentscheidung des Agenten	Eine übersehene Kleinstveränderung kann bis zu 2.500 EUR unbezahlte Arbeit bedeuten, eine verpasste Fehlerfrist ist nicht beziffert	offen

Modellkosten aus den n8n-Ausführungsdaten: Einordnen und Vertragsprüfung an 32 Mails vom 25.10.2026, 62.422 Token Eingabe und 5.440 Token Ausgabe, zusammen 0,032 US-Dollar. Trennen in Anliegen an 5 Mails vom 26.10.2026, im Mittel 822 Token Eingabe und 96 Token Ausgabe. Enthält eine Mail zwei Anliegen, läuft die Prüfung zweimal. Der Stundensatz von 48,50 EUR ist die Mitte des Arbeitslohns der Projektleitung aus Kapitel 3 (43 bis 54 EUR).

6. Nutzen und ROI

Je Mail spart die Projektleitung 9 bis 14 Minuten Arbeitszeit, das sind 7,28 bis 11,32 EUR gemessen. Wie lange eine Mail heute im Postfach liegt, lässt sich unter Laborbedingungen nicht messen und bleibt offen. Das Protokoll speichert dafür Eingang und Entscheidung jedes Falls. Die Zahl der Mails im Monat ist nicht gemessen, wir rechnen mit 80 und einer Bandbreite von 40 bis 120 Annahme. ROI = (Nutzen − Kosten) / Kosten.

Mails im Monat	Nutzen im Jahr	Kosten im 1. Jahr	ROI im 1. Jahr	ROI ab dem 2. Jahr	Aufbau bezahlt nach
40	3.492 bis 5.432 EUR	6.791 EUR	−49 bis −20 %	+20 bis +87 %	über 18 Monaten
80	6.984 bis 10.864 EUR	6.791 EUR	+3 bis +60 %	+140 bis +273 %	6 bis 11 Monaten
120	10.476 bis 16.296 EUR	6.791 EUR	+54 bis +140 %	+260 bis +460 %	4 bis 6 Monaten

Bei 80 Mails im Monat rechnet sich der Agent im ersten Jahr knapp, bei 40 erst ab dem zweiten. Nicht eingerechnet sind vermiedene unbezahlte Entwicklerarbeit, vermiedene Fristverletzungen und das von den Verträgen verlangte Protokoll. Der Nutzen ist also vorsichtig gerechnet.

7. Überwachung nach dem Einsatz

Zusätzlich zu den Kennzahlen aus Abschnitt 1 prüft die Projektleitung:

Was	Intervall	Schwellenwert
Wie oft die Projektleitung den Vorschlag des Agenten überstimmt	wöchentlich	über 20 % in vier Wochen: Regeln prüfen
Fälle, die laut Protokoll nach Slack gehen sollten, dort aber nie angekommen sind	täglich	jeder fehlende Fall wird geklärt
Technische Fehler, die nur im Protokoll stehen und keine Slack-Karte erzeugen	täglich	jeder Fall wird von Hand nachgeholt
Reaktionszeit bei Fehlermeldungen	täglich	Frist laut Vertrag, etwa 24 Stunden bei Kunde A, 4 Stunden bei Kunde B

Eskalationsschwellen. Die Startwerte aus Kapitel 4 (0,6 und 0,7) haben unklare Fälle mit Sicherheitswerten von 0,1 bis 0,5 zuverlässig an Menschen gegeben. Falsche Kategorien hatten aber teils einen Sicherheitswert von 0,9. Die Schwellen bleiben deshalb bei den Startwerten und ersetzen die Freigabe von Zusatzleistungen nicht.

Menschliche Prüfung und Abschaltung. Sinkt K1 oder K2 unter den Zielwert, prüft die Projektleitung jeden Vorschlag einzeln gegen den Vertrag, bis die Regeln verbessert sind. Erreichen Kontaktdaten das Sprachmodell oder bleibt eine Fehlermeldung ohne Slack-Meldung oder Reaktion, wird der Eingang abgeschaltet, und alle Mails werden von Hand bearbeitet, bis die Ursache behoben und getestet ist. Das gilt auch nach einem Wechsel des Sprachmodells.

8. Einordnung und nächste Schritte

Die Tests liefen unter Laborbedingungen mit Fällen, die die Gruppe selbst erstellt und ausgewertet hat. Sie zeigen, dass der Agent die vorgesehenen Fallarten sicher bearbeitet. Wie er mit Formulierungen echter Kunden umgeht, zeigt der Pilot im Parallelbetrieb (Kapitel 4). Die Testrunden bauten aufeinander auf, und einzelne Beispiele sind in die Anweisungen an das Modell eingeflossen, um die Einordnung zu vereinheitlichen. K1 und K2 beruhen auf 31 und 36 Mails. Für den Pilot legen wir die erwartete Einordnung jedes Falls vorab fest, lassen sie von zwei Personen unabhängig bestätigen und sichern zu jeder Testrunde den Stand des Workflows.

Das Sprachmodell antwortet nicht immer gleich: Bei wiederholten Mails schwankte die Kategorie zwischen B und C. Diese Schwankung fängt die Freigabe der Zusatzleistungen ab. Offen ist die Prüfung der Regeln im Programmcode.