Kapitel 6: Projektabschluss und Ausblick

Nordlicht KI-Werkstatt GmbH · Stand 28.10.2026

Die Kapitel 1 bis 5 haben das Problem beschrieben, die Einsatzbereiche eingegrenzt, die Werkzeuge verglichen, die Einführung geplant und den Agenten gemessen. Dieses Kapitel schaut auf das Ganze zurück: Was hat funktioniert, wo sind die Grenzen, welche Entscheidungen hatten einen Preis, und was kommt als Nächstes. Wir halten uns an dieselbe Kennzeichnung wie in Kapitel 5: **gemessen** aus Tests oder Protokoll, **Annahme** der Gruppe, **offen**, wo noch keine Daten vorliegen. Alle Firmen und Mails sind erfunden, die Tests liefen unter Laborbedingungen.

1. Wo wir stehen

Das Ziel aus Kapitel 1 war, dass die Projektleitung nicht mehr jede Kundenäußerung selbst gegen einen von fünf Verträgen prüft, sondern einen fertigen Vorschlag bekommt. Der Agent läuft dafür in n8n von Anfang bis Ende: Mail aus dem Postfach-Ordner holen, Kontaktdaten unkenntlich machen, die Mail in Anliegen trennen, jedes Anliegen einordnen, gegen den Vertrag prüfen, Zitat und Kontingent kontrollieren, eine Slack-Karte zur Freigabe erzeugen und den Fall protokollieren. Alle sechs Erfolgskriterien aus Kapitel 1 sind an den Testmails erreicht.

Kriterium	Zielwert	Ergebnis	Stand
K1 Zusatzleistungen erkannt	mindestens 95 %	100 %, 31 von 31 Mails mit Zusatzanteil	**gemessen**
K2 Kategorie richtig	mindestens 80 %	94 %, 34 von 36 Mails	**gemessen**
K3 Zeitersparnis	mindestens 50 %	69 bis 78 %: von Hand 13 bis 18 Minuten, mit Agent 4 Minuten	**gemessen**
K4 Kontaktdaten geschützt	keine beim Sprachmodell	Das Modell erhielt nur Platzhalter	**gemessen**
K5 Vorschlag innerhalb einer Minute	unter 1 Minute	Mittel 5,4 Sekunden (32 Läufe)	**gemessen**
K6 ROI je Durchgang	größer als 3	über 4.800	Kosten **gemessen**, Nutzen **Annahme**

Quelle: Kapitel 5, Abschnitt 4. K1 und K2 beruhen auf 31 und 36 Mails, die Testmengen stammen aus der Gruppe.

2. Was gut funktioniert hat

- **Die Sicherheit kommt aus dem Aufbau, nicht aus dem Modell.** Das Modell schlägt nur vor. Ein Programmschritt prüft, ob das Zitat wörtlich im Vertrag steht, Regeln rechnen Kontingent und Preis, und Zusatzleistungen sowie unsichere Fälle gibt ein Mensch frei. Im Probebetrieb (Kapitel 3) gingen erfundene Zitate, leere Modellantworten und unsichere Einstufungen an die Projektleitung, statt still durchzulaufen. Der Manipulationsversuch in den Testmails wurde nicht befolgt (Kapitel 5).
- **Der Datenschutz hält.** E-Mail-Adressen, Telefon- und Kontonummern erreichten das Sprachmodell in keinem Test, das Modell sah nur Platzhalter (K4).
- **Der Agent ist schnell und billig.** Ein Vorschlag liegt nach rund 5 Sekunden vor und kostet im Mittel rund 0,15 US-Cent je Mail.

- **Das Testen in Runden hat Fehler gefunden, bevor sie teuer wurden.** Fünf Testrunden mit insgesamt 90 Läufen (60 verschiedene Mails) haben die Einordnung Schritt für Schritt verbessert. In der letzten Runde bestanden alle zehn Mails nach den Änderungen. Auch der Probebetrieb in Kapitel 3 hat zwei Fehler im eigenen Aufbau aufgedeckt.

3. Grenzen und Fehlermuster

Die wichtigste Grenze ist die Aussagekraft der Tests. Sie liefen unter Laborbedingungen, die Gruppe hat Testfälle und Musterlösung selbst erstellt, und einzelne Beispiele aus den Tests sind in die Anweisungen an das Modell eingeflossen. Das Ergebnis fällt dadurch eher günstig aus. Wie der Agent mit den Formulierungen echter Kunden umgeht, zeigt erst der Pilot.

Fehlermuster	Wirkung	Stand
Zwei Anliegen in einer Mail, eines ging verloren	Eine Fehlermeldung, die zusammen mit einem Wunsch kam, ging an den Vertrieb statt an die Entwicklung. Die vertragliche Reaktionsfrist (bei Kunde B 4 Stunden) wäre verstrichen. Das war der teuerste Fehler.	Behoben: ein vorgeschalteter Schritt trennt die Mail in Anliegen. Im Nachtest belegt.
Seitenkontingent nicht gerechnet	Ein Auftrag über 45 Seiten bei 20 übrigen Seiten ging als „enthalten“ ohne Freigabe an die Entwicklung, eine übersehene Zusatzleistung.	Behoben: eine Regel rechnet die Seiten. In Runde 5 belegt. Der Begründungstext des Modells widersprach dem Ergebnis teilweise noch.
Regeln aus dem Prompt nicht zuverlässig befolgt	Das Modell nannte trotz Verbot den Buchstaben einer Kategorie als Vertragsstelle, schätzte Beträge und hielt eine Verständnisfrage für eine Fehlermeldung.	**offen**: wichtige Regeln sollen im Programmcode geprüft werden, nicht nur im Prompt.
Die Kategorie schwankt	Bei wiederholten Mails derselben Art wechselte die Einstufung zwischen B und C.	Die Freigabe der Zusatzleistungen fängt es ab, der Pilot zeigt, wie oft es vorkommt.
Zwei Änderungen der Kategorie A in einer Mail	Beide werden einzeln gegen dasselbe Kontingent geprüft, nicht zusammen.	Bekannte Grenze, **offen**.

4. Entscheidungen und Zielkonflikte

Bei den wichtigsten Entscheidungen gab es keine Lösung ohne Preis. Hier steht, welche Seite Vorrang bekam und was wir dafür in Kauf nehmen.

Zielkonflikt	Entscheidung und Grund	Preis
Datenschutz gegen Leistung	V1 mit Cloud-Modell statt eines lokalen Modells oder reiner Regeln. Nur unkenntlich gemachter Text verlässt das Haus. Freitext gegen Vertragstext auszulegen leistet ein Sprachmodell besser als feste Schlüsselwörter.	Geschwärzter Text geht an einen Anbieter. Ein Vertrag zur Auftragsverarbeitung ist vor dem Pilot nötig und **offen**.

Kontrolle gegen Entlastung	Zu Projektbeginn sollte die Projektleitung jeden Vorschlag freigeben. Im Verlauf wurde der Weg schlanker: Fehlermeldungen und als „enthalten" eingestufte Wünsche gehen ohne Freigabe an die Entwicklung. Eine Freigabekarte bekommen Zusatzleistungen, Eskalationen und unsichere Fälle. Ausnahme Kunde E, dessen Vertrag die Entscheidung einem Mitarbeiter vorbehält.	Ein fälschlich als „enthalten" eingestufter Wunsch erreicht die Entwicklung ohne Prüfung. Die wöchentliche Stichprobe zu K1 kontrolliert genau diesen Weg.
Flexibilität gegen Vorhersagbarkeit	Das Modell versteht auch unerwartete Formulierungen, deshalb bauen wir kein regelbasiertes V2. Alles Verbindliche bleibt bei Regeln und Menschen.	Das Modell antwortet nicht immer gleich, die Kategorie schwankt.
Schwellen gegen Freigabe	Die Startwerte 0,6 und 0,7 blieben. Unklare Fälle hatten Sicherheitswerte von 0,1 bis 0,5, falsche Kategorien aber teils 0,9. Die Schwellen fangen also unsichere Fälle zuverlässig, falsche Einstufungen mit hohem Sicherheitswert aber nicht. Deshalb ersetzen sie die Freigabe von Zusatzleistungen nicht.	Die Schwellen bleiben Startwerte. Gegen eine sicher vorgetragene Fehleinstufung hilft nur die Freigabe.
Modellwahl gegen Unabhängigkeit	Der Kurs der MSIT gibt über OpenRouter nur Gemini 2.5 Flash frei. Wir haben deshalb keine anderen Modelle getestet.	Wir sind an einen Anbieter gebunden und arbeiten mit einem vergleichsweise alten und schwachen Modell. Wie viel ein besseres Modell bringen würde, wissen wir nicht.

5. Wirtschaftlichkeit

Der Agent kostet nach dem Aufbau wenig. Ein Durchgang kostet rund 0,15 US-Cent, n8n läuft lokal ohne Lizenz. Dazu kommen einmalig rund 3.880 EUR für den Aufbau (80 Stunden zu 48,50 EUR, **Annahme**) und laufend rund 2.910 EUR im Jahr für die Pflege (5 Stunden im Monat, **Annahme**). Je Mail spart die Projektleitung 9 bis 14 Minuten, das sind 7,28 bis 11,32 EUR **gemessen** an der Zeit, der Wert der Zeit ist eine **Annahme**. Je Durchgang liegt der ROI deshalb über 4.800. Über das Jahr gerechnet fällt das Bild nüchterner aus, weil der Aufbau ins erste Jahr zählt:

Mails im Monat	Nutzen im Jahr	Kosten im 1. Jahr	ROI im 1. Jahr	ROI ab dem 2. Jahr	Aufbau bezahlt nach
40	3.492 bis 5.432 EUR	6.791 EUR	−49 bis −20 %	+20 bis +87 %	über 18 Monaten
80	6.984 bis 10.864 EUR	6.791 EUR	+3 bis +60 %	+140 bis +273 %	6 bis 11 Monaten
120	10.476 bis 16.296 EUR	6.791 EUR	+54 bis +140 %	+260 bis +460 %	4 bis 6 Monaten

Die Zahl der Mails im Monat ist nicht gemessen. Wir rechnen mit 80 und einer Bandbreite von 40 bis 120 (**Annahme**). Bei 80 Mails rechnet sich der Agent im ersten Jahr knapp, bei 40 erst ab dem zweiten. Nicht eingerechnet sind vermiedene unbezahlte Entwicklerarbeit, vermiedene Fristverletzungen und das von den Verträgen verlangte Protokoll, der Nutzen ist also vorsichtig gerechnet. Offen bleibt das Risiko einer Fehlentscheidung: Eine übersehene Kleinstveränderung kann bis zu 2.500 EUR unbezahlte Arbeit bedeuten.

6. Nächste Schritte

Die Schritte folgen aus den Grenzen oben und sind nach Zeitpunkt geordnet.

JETZT

Vorbereitung des Piloten und Regeln im Programmcode absichern

Das ist die Vorbereitungsphase aus Kapitel 4 (zwei Wochen): Vertrag zur Auftragsverarbeitung mit dem Modellanbieter, Kundenstamm und Vertragskurzfassungen einpflegen, Slack-Kanäle anlegen, Vertretung schulen, Empfänger einweisen. Dazu gehört, die wichtigen Regeln im Programmcode zu prüfen statt nur im Prompt.

Warum zuerst: Ohne Auftragsverarbeitungsvertrag darf kein echter Kundentext an das Modell. Und die Regelprüfung im Code schließt die offene Schwäche, bevor der Agent echte Mails sieht.

DANACH

Pilot im Parallelbetrieb, anschließend Live-Betrieb

Mindestens vier Wochen, alle fünf Kunden von Anfang an. Die Projektleitung entscheidet jeden Fall zunächst selbst und gleicht ihr Ergebnis mit dem Vorschlag des Agenten ab. Die erwartete Einordnung jedes Falls wird vorab festgelegt und von zwei Personen unabhängig bestätigt. Der Pilot misst, was wir nur schätzen konnten: die Zahl der Mails im Monat, die Zeit je Fall im echten Betrieb, wie oft die Projektleitung dem Agenten widerspricht und wie oft die Kategorie schwankt. Sind K1, K2 und K4 erreicht, geht der Pilot in den Live-Betrieb über. Sonst wird er verlängert und nachgebessert.

Warum danach: Er braucht die Vorbereitung als Voraussetzung. Erst er zeigt, wie der Agent mit den Formulierungen echter Kunden umgeht, und erst er macht aus Annahmen in der Wirtschaftlichkeit Messwerte.

SPÄTER

Andere Sprachmodelle testen

Wir haben nur Gemini 2.5 Flash getestet, weil der Kurs nur dieses Modell freigibt. Das bindet uns an einen Anbieter und an ein vergleichsweise altes, schwaches Modell. Der Ablauf ist darauf vorbereitet: Das Modell ist ein austauschbarer Schritt, und die Testmenge lässt sich mit jedem anderen Modell wiederholen. Ein lokales Modell (V3 aus Kapitel 3) bleibt die Rückfallebene, falls sich der Datenweg als nicht ausreichend erweist.

Warum später: Ein fairer Vergleich braucht die Pilotwerte als Ausgangspunkt, und für den Test braucht es einen Zugang außerhalb des Kurses. Ob ein besseres Modell die schwankende Kategorie und die Regelverstöße verringert, ist die Frage, die der Test beantworten soll.

Als Ausbaustufen, die den Ablauf nicht ändern, sind in Kapitel 4 die Anbindung eines Ticketsystems und die Freigabe per E-Mail als Rückfall vorgesehen.

7. Was wir mitnehmen

- **Früh testen lohnt sich.** Der teuerste Fehler, die verlorene Fehlermeldung in einer Mehrfach-Mail, wurde erst durch die Auswertung der Testmails sichtbar.
- **Verbindliches gehört in Regeln, nicht in den Prompt.** Beim Seitenkontingent und bei den Kategorie-Buchstaben hat der Prompt allein nicht gereicht.
- **Pläne ändern sich, wenn man sie misst.** Den ursprünglichen Plan der Freigabe jedes Vorschlags haben die Tests verändert. Kapitel 1 und 3 beschreiben deshalb weiter den ursprünglichen Plan, Kapitel 5

begründet die Änderung.

8. Zusammenarbeit und persönliche Reflexion

Reflexion von Knut

Umsetzung und Dokumentation. Die technische Umsetzung des Agenten war gut zu bewältigen. Den größten Zeitaufwand verursachte die Ausarbeitung der schriftlichen Kapitel nach den Vorgaben der MSIT. Eine Dokumentation des Projekts halte ich für wichtig, und ich kann nachvollziehen, dass für Ausbildung und Abschluss ein Einblick in das Projekt und in die Denkweise der Entwickler gewünscht ist. Für mich nicht schlüssig ist jedoch, warum für einen so kleinen Agenten derart viel ausgearbeitet und teilweise wiederholt werden muss. Der geforderte Umfang geht aus meiner Sicht deutlich über das Maß hinaus, das für einen Agenten dieser Größe nötig wäre. Ob einzelne Punkte in der betrieblichen Praxis in dieser Form verlangt werden, kann ich nicht beurteilen. Sie waren Teil der Aufgabe, und wir haben sie vollständig bearbeitet.

Zusammenarbeit im Team. Eine übergeordnete Planung gab es nicht, wir haben das Projekt eigenständig entwickelt und es ist das Ergebnis gemeinsamer Arbeit. Da die Vorstellungen der Beteiligten teilweise voneinander abwichen, mussten wir uns regelmäßig abstimmen und auf ein gemeinsames Vorgehen einigen. Wir sind zu dritt gestartet, ein Teammitglied ist jedoch bereits früh im Verlauf ausgeschieden. Das Projekt ist deshalb im Wesentlichen eine Arbeit zu zweit. Das vereinfachte die Abstimmung, bedeutete aber einen höheren Arbeitsaufwand für uns beide.

Einsatz von AI-Assistenten. Die Unterstützung durch AI-Assistenten war eine große Hilfe. Sie neigen jedoch dazu, über den gestellten Auftrag hinauszugehen. Ihre Ergebnisse müssen deshalb geprüft und eingeordnet werden, anstatt ihnen ohne Kontrolle zu vertrauen. Andernfalls besteht das Risiko von Fehlern und von einer unkontrollierten Ausweitung des Projekts oder des Use Cases. Beim Arbeiten mit AI-Assistenten gehört es daher dazu, die einzelnen Bestandteile aufeinander abzustimmen und die Gesamtarbeit zu steuern.

Freude am Projekt und Ausblick. Die Entwicklung des Projekts hat mir viel Freude bereitet. Ich sehe darin eine Basis, die sich deutlich ausbauen lässt, denn der Agent deckt nur einen kleinen Teil dessen ab, was sich in diesem Umfeld automatisieren lässt. Für die Weiterentwicklung habe ich bereits mehrere Ideen, etwa die vollständige Verarbeitung des Mailverkehrs oder die Unterstützung bei der Abstimmung mit Kunden, die dann weiterhin eine menschliche Freigabe und die Vorgaben des Datenschutzes berücksichtigen müsste. Das Ziel wäre, dass es nicht bei diesem einen Workflow bleibt, sondern dass daraus ein agentisches Gesamtsystem entsteht, in dem dieser Workflow nur ein Baustein ist. Ein solches System lässt sich zudem deutlich weiter skalieren.

Reflexion von Michael

Umsetzung und Dokumentation. Knuts Eindruck teile ich: Den größten Aufwand hat nicht der Agent selbst verursacht, sondern alles, was ihn nachvollziehbar und prüfbar macht. Die Dokumentationsvorgaben der Prüfung waren sehr umfangreich und haben für einen Agenten dieser Größe einen großen Teil unserer Arbeitszeit gebunden. Mein Teil lag vor allem davor und danach. Bevor der Agent etwas prüfen konnte, brauchte er Verträge mit einem klaren, einheitlichen Änderungsverfahren. Erst dadurch ließ sich überhaupt eindeutig sagen, was enthalten ist und was eine Zusatzleistung. Nach dem Bau zeigten die Testmails, wo der Agent noch daneben lag, und aus jeder Testrunde ergaben sich konkrete Änderungen am Workflow. Am meisten gelernt habe ich dabei, dass eine Mail nicht einfach richtig oder falsch eingeordnet ist. Wir mussten vorher festlegen, welche Wege fachlich vertretbar sind, sonst wäre jede Zahl angreifbar gewesen. Grundsätzlich nehme ich mit: Je gründlicher eine Aufgabe vorher vorbereitet und von allen Seiten beleuchtet wird, desto leichter wird die Umsetzung und desto weniger muss hinterher geändert werden.

Zusammenarbeit im Team. Wie Knut schreibt, war es im Wesentlichen eine Arbeit zu zweit, die viel Abstimmung brauchte. Dabei habe ich gemerkt, wie wichtig es ist, dass eine Person den Überblick behält und die Fäden in der Hand hält. In unserem Fall war das Knut, und er hat das sehr gut gemacht. Die Aufteilung, dass er baut und ich teste, hat funktioniert, weil die Wege kurz waren und die Prüfung in beide Richtungen wirkte: Knut hat einen Fehler in meiner Auswertung gefunden, und mir ist eine Lücke im Freigabeweg bei Kunde E aufgefallen, die er noch am selben Tag geschlossen hat. Nicht gut lief, dass der Workflow während meiner Tests weiterentwickelt wurde, ohne dass wir den jeweiligen Stand gesichert hatten. Dadurch lassen sich manche Ergebnisse nicht eindeutig einer Fassung zuordnen. Beim nächsten Mal würde ich vor jedem Testlauf den Stand sichern und kurz absprechen, was sich geändert hat, und meine eigenen Dateien von Anfang an ordentlicher strukturieren.

Einsatz von AI-Assistenten. Auch ich habe Claude eingesetzt, vor allem für wiederkehrende Arbeit wie Auswertungstabellen, Vergleiche zwischen den Testrunden, Rechnungen und das Formatieren der Dokumente. Das hat viel Zeit gespart. Wie Knut habe ich aber erlebt, dass die Ergebnisse geprüft werden müssen: Der Fehler in meiner Auswertung entstand genau so, die Begründung klang schlüssig, war fachlich aber falsch. Wichtig war mir deshalb, dass Testergebnisse nur aus echten Läufen stammen und nichts vorab als bestanden eingetragen wird.

Ausblick. Das Projekt war für mich sehr spannend. Ich kann mir gut vorstellen, dass ein solcher Agent tatsächlich bei einem Kunden zum Einsatz kommt. Sein Umfang lässt sich Baustein für Baustein erweitern, bis daraus ein agentisches System wird, das einer Firma spürbar Zeit und Geld spart. Das Ergebnis wäre greifbar: Statt täglich mehrere Stunden Mails zu lesen, weiterzuleiten und hin und her zu schicken, ist das Postfach aufgeräumt, und jede Person bearbeitet nur noch das, was sie wirklich betrifft. Genau in diesem Bereich möchte ich selbst aktiv werden und KI und agentische Systeme in Unternehmen bringen.